

Фабрика гипотез: генерация технологических гипотез для обогащения и металлургии

Whitepaper · Task 1, Норникель AI Science Hack

Аннотация

Система «Фабрика гипотез» принимает на вход описание технологической проблемы обогатительной фабрики — профиль хвостов (потери Ni/Cu/Au/Ag по крупности и минеральным формам), схему аппаратов, ограничения — и возвращает ранжированный список проверяемых технологических гипотез. Система спроектирована так, чтобы существенные утверждения и численные оценки в гипотезе были прослеживаемо связаны с проверенным фактом из корпуса профессиональной литературы. Факты, не прошедшие детерминированную проверку обоснования, не попадают в базу и не могут служить доказательной основой гипотезы.

Три инженерных решения отличают систему от стандартного подхода «GPT поверх RAG»:

1. **Приоритет обоснования (grounding-first).** Факт отсеивается детерминированной проверкой кода до записи в базу данных, а не доверием к модели.
2. **Детерминированные границы доверия.** Наличие аппарата на фабрике проверяется SQL-запросом, а не векторным поиском; ранжирование — воспроизводимая взвешенная сумма, а не дополнительный вызов LLM.
3. **Прослеживаемость.** Весь путь «источник → факт → гипотеза → оценка» прозрачен и воспроизводим.

Все описанное ниже работает на действующем стенде: корпус из 51 документа и 46 514 чанков в двух доменах (отчетные документы сжаты из более чем 200 научных статей), 84 сгенерированные гипотезы за 19 прогонов, 173 извлеченных и проверенных факта.

1. Постановка проблемы

На действующей фабрике теряется металл — например, никель уходит в хвосты в закрытых сродках пентландита и халькопирита во фракции +71 мкм. Технологию нужны не общие рассуждения о флотации, а набор конкретных проверяемых направлений, каждое из которых опирается на профессиональную литературу и учитывает реальные ограничения площадки: нельзя останавливать схему, на фабрике стоят определенные аппараты.

Наивное решение — задать вопрос большой языковой модели или использовать классический RAG — не подходит по трем причинам.

Во-первых, галлюцинации цифр недопустимы. Рекомендация «уменьшите крупность до 45 мкм — получите +6% извлечения» без источника — это выдумка, которая в металлургии стоит денег и доверия.

Во-вторых, непрослеживаемость. Ответ языковой модели нельзя проверить: неизвестно, откуда взята рекомендация. Даже если модель приводит цитату, она не гарантированно подтверждает утверждение — соответствие цитаты и тезиса остается отдельной проблемой [6].

В-третьих, невоспроизводимость. Один и тот же запрос дает разные ответы; ранжирование «на глаз» моделью неустойчиво.

Нужна система, в которой каждое утверждение имеет источник, ничего не выдумывается, а приоритизация детерминирована.

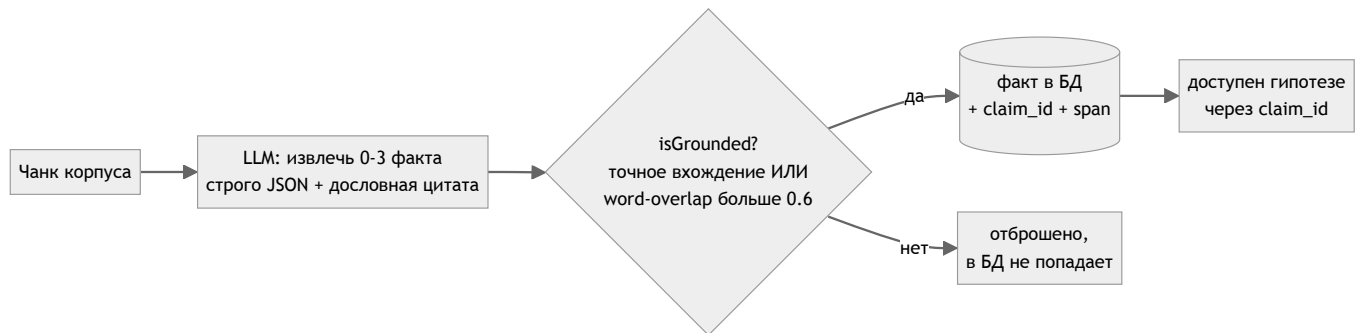
2. Отличия от существующих подходов

Генерация гипотез с помощью языковых моделей — известное направление, но существующие подходы ориентированы на научное открытие «вообще», а не на проверяемое промышленное решение с ограничениями конкретной фабрики.

Подход	Что делает	Ограничение для промышленного применения	Отличие «Фабрики гипотез»
Swanson / LBD (ABC-модель) [1]	Находит скрытые связи А–В–С между разрозненными публикациями	Подходит для discovery, слабо учитывает оборудование, экономику и проверяемость на площадке	Гипотеза привязана к идентификатору факта, профилю хвостов, оборудованию фабрики и KPI
AI co-scientist (multi-agent) [2]	Генерация, ранжирование и «эволюция» научных гипотез с привязкой к веб-источникам	Универсальная научная система без учета границ оборудования и профиля хвостов	Уже по охвату, но промышленно детерминирована: RAG + SQL-ограничения + воспроизводимая оценка
SciAgents (граф знаний + LLM + агенты) [3]	Discovery-петля поверх графа знаний	Фокус на научной генерации, а не на отбраковке на уровне фактов и применимости	Проверка обоснования до записи в базу: гипотеза не проходит без источника
KG-augmented (HyKGE и аналоги)	Связывает сущности через граф для объяснимости	Граф сам по себе не гарантирует, что текстовое утверждение подтверждено источником	Утверждения валидируются по фрагменту источника; граф репутации — слой ранжирования, не единственный критерий
Обычный RAG-чат по документам	Ищет чанки, генерирует ответ с цитатами	Цитата может не подтверждать утверждение; ранжирование недетерминированно	Проверка на уровне факта + ансамбль критиков + воспроизводимая взвешенная сумма

3. Ключевая идея: приоритет обоснования

Центральный принцип: факт не существует для системы, пока не подтвержден цитатой из источника. Проверка обоснования применяется на уровне отдельного утверждения, а не ответа целиком.



На каждый найденный фрагмент выполняется узкий вызов LLM, извлекающий 0–3 факта строго в формате JSON с дословной цитатой-основанием. Соседние чанки того же документа подмешиваются как родительский контекст — так разрезанная при чанкинге таблица не теряет смысл.

Проверка обоснования выполняется кодом, а не моделью. Проверка пройдена, если цитата либо дословно входит в нормализованный текст источника, либо подтверждается близким фрагментом с пословным перекрытием не ниже 0.6. Второй режим нужен для устойчивости к OCR, переносам строк, таблицам и нормализации текста. Не прошедший проверку факт никогда не записывается в базу — это структурная, а не декларативная защита от галлюцинаций.

Как следствие: гипотеза, опирающаяся только на регламенты текущего состояния (без литературы об эффекте изменения), сознательно не содержит предписаний вида «уменьшить X до Y». Это осознанный компромисс в пользу отсутствия выдумок.

Если для целевого металла или точки потерь не нашлось ни одного факта, прогон явно сообщает о пробеле в отчете вместо тихой деградации.

На текущем корпусе извлечено и прошло проверку 173 факта (уверенность: средняя — 130, высокая — 41, низкая — 2; конфликтов не помечено), происходящих из 14 документов. Каждый факт доступен гипотезам по идентификатору.

4. Архитектура

Три сервиса, запускаются одной командой `docker compose up` :

Сервис	Технологии	Роль
api	Go, Fiber v2, GORM	Оркестрация пайплайна, REST API, отчеты
pyworker	Python, FastAPI	Эмбединги BGE-M3 (мультиязычные, до 8192 токенов) + реранкинг bge-reranker-v2-m3
postgres	pgvector/pgvector:pg16	Корпус, эмбединги <code>vector(1024)</code> , полнотекстовый <code>tsvector</code> , HNSW-индекс

Корпус текущей сборки:


Показатель	Значение
Документов в базе	51
Типы источников	книги — 17, отчеты — 15, схемы — 14, исторические кейсы — 4, регламенты — 1
Первичных научных статей в основе	более 200 — сжаты в отчетные документы (15 дайджестов)
Домены (заполнены)	флотация — 41, гидрометаллургия золота — 10
Чанков	46 514 (100% с эмбедингами)
Табличных чанков	4 216 (9%) — чанкинг с учетом таблиц

Из 51 документа 15 — это отчетные дайджесты, агрегированные более чем из 200 научных статей. Сжатие потока статей в плотные, тематически структурированные документы повышает отношение сигнала к шуму при извлечении фактов и сокращает дублирование доказательной базы.

Тяжелая загрузка (парсинг PDF через Docling, OCR EasyOCR-ru, транскрипция схем) вынесена в отдельный профиль и не входит в runtime-стек. GPU нужен только для наполнения базы, а не для работы системы. Двух заполненных доменов достаточно, чтобы подтвердить: мультидоменность работает на практике — второй домен подключен без изменения ядра.

Пайплайн (7 стадий, асинхронный)

POST /v1/runs разбирает описание проблемы и сразу возвращает 202 + id + разобранный problemSpec за 1–2 секунды; остальное считается в фоне, клиент опрашивает GET /v1/runs/:id .



Стадия	Что происходит
retrieving	Фасетный гибридный поиск + реранкинг
extracting	Извлечение фактов с проверкой обоснования
generating	Генерация 5–10 гипотез со ссылками на факты
critiquing	Ансамбль из 3 судей + детерминированное ранжирование
done / failed	Готовый отчет или явная ошибка

Полный прогон пайплайна на CPU — около 3 минут.

Технологический стек

Стек держится на трех решениях. Векторный поиск, реляционные данные и полнотекстовый поиск находятся в одной PostgreSQL, а не в отдельном vector store: это убирает синхронизацию хранилищ и дает фильтрацию по фасетам и векторный поиск одним SQL. ML вынесен в отдельный Python-сайдкар, поэтому Go-ядро остается легким. Runtime рассчитан на CPU, а тяжелый GPU-ingestion вынесен в отдельный профиль и в работу системы не входит.

Два инженерных решения стоит выделить отдельно. Первое: runtime-стек (postgres + pyworker + api) поднимается на CPU любой машины жюри одной командой docker compose up — GPU нужен только для offline-наполнения корпуса. Второе: LLM подключается через интерфейс LLMClient и заменяется без правки ядра — YandexGPT можно поменять на self-hosted OpenAI-совместимый эндпоинт (vLLM или Ollama + Qwen3), не трогая логику генерации гипотез и критиков.

Backend / API

Инструмент (версия)	Роль	Почему сильный выбор
Go 1.25.0	Ядро: оркестрация пайплайна, REST API	Один статический бинарь и нативная конкурентность для параллельного retrieval и ансамбля критиков
Fiber v2.52.13	HTTP-слой	На fasthttp — дешевый по накладным расходам, когда один <code>/v1/runs</code> порождает десятки под-запросов
GORM v1.31.1 + драйвер postgres	ORM для базовых колонок и связей	Стандартные таблицы через ORM, а pgvector-тип, GENERATED-колонки и HNSW — raw SQL там, где нужен контроль
google/uuid v1.6.0	Генерация ключей	Идентификаторы без координации — безопасно при распределенном ingestion
swagger/swagger v1.16.4 + gofiber/swagger	Контракт API из аннотаций	Swagger генерируется из кода хендлеров, поэтому контракт не расходится с реализацией

Хранилище и поиск

Инструмент (версия)	Роль	Почему сильный выбор
PostgreSQL 16 + pgvector (pgvector/pgvector:pg 16)	Единое хранилище: вектор <code>vector(1024)</code> + реляционка + FTS	Фильтрация по домену/типу источника и векторный поиск одним SQL, транзакционная целостность, бэкап дампом
HNSW-индекс (vector_cosine_ops)	ANN-поиск по чанкам и по сущностям	Суб-линейный поиск на ~46.5k чанков; cosine согласован с нормализацией эмбеддингов
<code>tsvector('russian')</code> GENERATED STORED + GIN	Полнотекстовый канал	Русский стемминг, колонка пересчитывается автоматически и не рассинхронизируется с текстом
Гибридный поиск (CTE в БД)	Слияние лексики и вектора	Взвешенное слияние <code>ts_rank</code> (0.4) и cosine (0.6) через FULL OUTER JOIN, top-50 каждого канала — целиком в БД

ML: эмбеддинги и реранк

Инструмент (версия)	Роль	Почему сильный выбор
BAAI/bge-m3	Плотные мультязычные эмбеддинги 1024-dim	Один язык модели покрывает ru + en + термины; <code>max_seq_length</code> = 8192 одинаково в runtime и ingestion, чтобы векторы запроса и документа не разъезжались
BAAI/bge-reranker-v2-m3	Cross-encoder реранк финального top-K	Видит пару «запрос — кандидат» целиком, поэтому точнее bi-encoder на коротком top-K; парный к BGE-M3
sentence-transformers ≥3.3	Инференс эмбеддингов и реранка	Осознанный отказ от FlagEmbedding, тянущего хрупкий decoder-only код
PyTorch (CPU в runtime; 2.8 на ROCm 6.4 в ingestion)	Рантайм моделей	В runtime CPU-only; в ingestion деградация размера батча при OOM вместо падения
Python-сайдкар (FastAPI, services/pyworker)	Изоляция ML от ядра	Go-бинарь остается легким; в runtime-сайдкаре только <code>/embed</code> и <code>/rerank</code>

LLM

Инструмент (версия)	Роль	Почему сильный выбор
YandexGPT (yandexgpt/latest ; corpus-scout — yandexgpt-lite)	Извлечение фактов, генерация гипотез, критики	Ru-домен под русскоязычный корпус; данные обогащения остаются в российском облаке — комплаенс по локальности
Семафор конкурентности (8 сессий)	Ограничение параллельных вызовов	Отражает лимит провайдера, защищает весь пайплайн и уважает отмену контекста
Интерфейс LLMClient	Точка подмены модели	Pluggable: замена на self-hosted OpenAI-совместимый эндпоинт (vLLM / Ollama + Qwen3) без правки services/hypothesisfactory

Ingestion и парсинг документов (offline-профиль tools/ingestion , вне runtime)

Инструмент (версия)	Роль	Почему сильный выбор
Docling 2.108.0	Семантический чанкинг PDF	Режет по секциям и сохраняет таблицы как таблицы — важно для извлечения фактов; есть пост-фиксы артефактов TableFormer
EasyOCR (ru + en)	OCR сканов	Замена RapidOCR, у которого нет кириллицы
GROBID 0.8.1	Структурный разбор научных статей	TEI XML (title/authors/abstract/секции) для sourceType=article — точнее Docling на академических PDF
Semantic Scholar Graph API v1	Метаданные статей	Best-effort сигнал авторитетности (цитируемость, год, venue, DOI); недоступность не роняет ingestion
Vision-LLM транскрипция схем	Оцифровка графических схем	Схемы обогащения переводятся в markdown там, где OCR бессилен

Инфраструктура / DevOps

Инструмент (версия)	Роль	Почему сильный выбор
Docker + Docker Compose (два профиля)	Сборка и запуск	Runtime поднимается на CPU одной командой; тяжелый GPU-ingestion вынесен в отдельный override-файл
pgvector/pgvector:pg16 + init-скрипты db/*.sql.gz	База с готовым корпусом	При первом старте пустого volume корпус восстанавливается автоматически
ROCm 6.4 (база ingestion, AMD GPU)	GPU-окружение наполнения	Пины torch под ROCm — воспроизводимая тяжелая загрузка вне runtime
healthcheck + depends_on	Порядок старта	api стартует только после healthy postgres
Multi-stage Go build	Образ ядра	Финальный образ — один статический бинарь плюс sa-certificates

Автопополнение корпуса (cmd/corpus-scout)

Инструмент (версия)	Роль	Почему сильный выбор
Каталог Geokniga	Источник новых книг	Тот же источник, что и ручной корпус, — согласованность качества доказательной базы
<code>net/http → POST /v1/documents</code>	Загрузка и подача документов	Новые книги идут тем же путем Docling + OCR + BGE-M3, что и ручной корпус
Детерминированный keyword-фильтр (+ опционально YandexGPT-lite)	Отбор релевантного	Воспроизводимо и бесплатно по умолчанию; LLM подключается опционально
Word-overlap дедуп (порог 0.6)	Отсев дублей	Не заводит в корпус уже имеющиеся материалы
Защиты: dry-run по умолчанию, <code>-max</code> бюджет, проверка <code>%PDF</code> , лимит размера	Предохранители	Автопополнение по умолчанию ничего не пишет и не выходит за бюджет

5. Методология

5.1. Разбор спецификации проблемы и защита от инъекций

Свободный текст преобразуется вызовом LLM в структуру: целевые металлы, точки потерь, оборудование, ограничения. Выбор фабрики защищен от prompt-injection: явный параметр `plant` перекрывает имя, извлеченное из текста, а пользовательский текст обернут в размеченный блок. Альтернативный вход — детерминированный `POST /v1/runs/from-excel`: числа берутся из файла «Хвосты *.xlsx» как есть, без участия LLM.

5.2. Фасетный гибридный поиск

Вместо одного запроса используется несколько детерминированных фасетов, каждый со своим независимым циклом: эмбединг → гибридный поиск → реранкинг.

Гибридный поиск объединяет лексический (полнотекстовый поиск PostgreSQL ловит точные названия минералов, реагентов, марок аппаратов) и плотный векторный (HNSW cosine в pgvector ловит семантику). Они сливаются взвешенной суммой, после чего реранкинг `bge-reranker-v2-m3` отбирает top-N [4].

Состав фасетов: базовый (формулировка проблемы) плюс по одному на каждый тип аппарата, реально стоящего на фабрике. Запрос фасета — типовые регулировочные «рычаги» аппарата из справочника. Например, для гидроциклона: песковая насадка, разгрузочное отношение, крупность слива; для мельницы: футеровка, шаровая загрузка. Для фабрик без структурированных данных предусмотрен fallback на статичные тематические фасеты домена.

Зачем нужна декомпозиция: единый реранкинг против общего минералогического запроса «топит» узкий контекст про конкретное оборудование ниже top-K. Раздельные фасеты собирают дополнительную доказательную базу и снижают смешение технологических контекстов.

Отбор в top-K — два прохода. Первый — гарантированный минимум слотов каждому фасету, но только для кандидатов с реранкер-оценкой не ниже 0.5 (защита от проталкивания мусора). Второй — открытый пул: остаток бюджета распределяется по конкуренции по сырой оценке с дедупликацией по идентификатору чанка и ограничением не более 2 добавочных слотов одному фасету (защита от затопления топа одним типом контента).

5.3. Оборудование фабрик как детерминированная граница доверия

Факт «какой аппарат стоит на фабрике» не может быть «средне релевантным» — он либо есть, либо нет. Поэтому данные об оборудовании (модели, параметры, положение в схеме) хранятся как строки в базе и подмешиваются в спецификацию проблемы детерминированным SQL-запросом по имени фабрики с учетом алиасов, а не векторным поиском. Это граница доверия: система не предложит аппарат, которого нет на площадке.

Пример реальной записи (фабрика ТОФ, 19 позиций в базе):

```
plant_name: ТОФ  aliases: [Талнахская обогатительная фабрика, Талнах, ...]
equipment_type: crusher  model: КМД-2200Т (×2)
circuit_position: Дробильный цех, поз. №1, №2
```

5.4. Генерация и ансамбль критиков

Гипотезы (5–10) генерируются одним вызовом LLM строго в формате JSON, каждая — со ссылками на идентификаторы фактов. В промпт подмешиваются: история обратной связи по упомянутым сущностям, список отклоненных направлений, язык вывода (русский, английский, китайский).

Оценивают три независимых LLM-судьи — технолог, экономист, рецензент новизны — параллельно, по пяти критериям. Итоговая оценка — детерминированная взвешенная сумма, а не дополнительный вызов модели. Ранжирование обязано быть воспроизводимым: одни веса — один порядок.

Критерий	Вес по умолчанию
Evidence (сила доказательной базы)	0.25
Impact (эффект на KPI)	0.25
Feasibility (реализуемость)	0.20
Novelty (новизна)	0.15
Risk penalty (штраф за риск)	0.15

Веса перенастраиваются на прогон. Эндпоинт `POST /v1/runs/:id/rerank` пересортировывает гипотезы без повторных вызовов LLM — это режим экспертной настройки.

5.5. Обучение на обратной связи через граф репутации сущностей

Экспертная оценка (подтверждено / отклонено / требует доработки) не инжектируется плоским текстом, а становится частью графа. Сущности — например, конкретная модель гидроциклона — разрешаются между прогонами через дедупликацию по сходству эмбедингов (cosine distance не более 0.10): одна сущность — один узел. Сейчас в графе 125 сущностей. Репутация вычисляется соединением таблиц фактов, гипотез и обратной связи и подмешивается в генерацию как история «эта сущность чаще подтверждалась или отклонялась». Это цикл обучения на обратной связи, а не самообучение LLM: воспроизводимость генерации сохраняется.

6. База знаний и доменное покрытие

Корпус — сквозная библиотека по всей цепочке передела благородных и цветных металлов. Область знаний зафиксирована четырехуровневой таксономией:

Уровень	Что это	Число
L1	Крупные домены	около 20
L2	Области	около 100
L3	Подобласти / темы	около 600
L4	Поисковые микротемы	более 1500

Двадцать доменов L1: геология и МСБ, экономика недропользования, минералогия, формы нахождения благородных металлов, общая теория обогащения, рудоподготовка, классификация и грохочение, гравитация, магнитно-электрическое обогащение, радиометрия и предконцентрация, флотация, флотореагенты, флотооборудование, обезвоживание, хвостовое хозяйство, металлургия благородных металлов, упорные руды и предо кислeние, бесцианидное выщелачивание, проектирование и автоматизация фабрик, аналитика, экология и промышленные кейсы.

Полная развертка (20 → 100 → 600) приведена в Приложении 2. Таксономия используется тройко: кураторская работа с корпусом (включая авторазведчик по каталогу Geokniga), доменная маршрутизация (новый передел подключается без правки ядра) и широта доказательной базы (одна гипотеза опирается на факты из нескольких доменов).

7. Оценка качества

Часть показателей измерена на действующем стенде, часть оформлена как протокол замера, требующий эталонной разметки или эксперимента. Цифры, которые не измерялись, не приводятся.

7.1. Измерено на текущем корпусе

Показатель	Значение	Что показывает
Покрытие эмбедингами	46 514 / 46 514 (100%)	Весь корпус доступен плотному поиску
Чанкинг с учетом таблиц	4 216 табличных чанков	Таблицы (сортовой состав, балансы) не теряются
Доменов заполнено	2 (флотация, гидрометаллургия золота)	Два передела в одном корпусе, без правки ядра
Извлечено фактов	173 (прошли проверку обоснования)	Все факты прошли grounding-проверку
Уверенность фактов	средняя 75%, высокая 24%, низкая 1%	Система маркирует силу доказательной базы
Сущностей в графе	125 (после дедупликации)	Сущности сведены в единый граф
Гипотез сгенерировано	84 за 19 прогонов (около 4.4 на прогон)	Полный цикл отработывает до отчёта
Воспроизводимость ранжирования	детерминирована архитектурно	Одни веса — один порядок
Время прогона (CPU)	около 3 минут	Работает на CPU, без GPU

7.2. Протокол замера (метрики определены, требуют эталонной разметки)

Блок	Метрики	Как замерить	Статус
Поиск	Recall@10/20, nDCG@10, MRR@10	40–60 запросов по фасетам (рудоподготовка, гидроциклоны, флотация Ni/Cu, Au/Ag, реагенты, хвосты), ручная разметка эталонных чанков, ablation: только dense / только FTS / гибрид / гибрид + реранкер / фасеты + реранкер	требуется эталонная разметка
Обоснование	доля подтвержденных фактов, доля неподтвержденных, несоответствие цитат, доля отбраковки [5]	50–100 гипотез → разбить обоснование на атомарные факты → проверить фрагмент/перекрытие/поддержку; ablation с проверкой и без	требуется прогон-эксперимент
Качество гипотез	новизна / правдоподобность / реализуемость / влияние на KPI / риск (1–5) + согласие оценщиков (каппа Коэна / Спирмен)	2–3 LLM-судьи + 1 технолог оценивают top-N, считается средняя оценка, разброс, согласие	требуется экспертная сессия

Ablation «с проверкой обоснования / без» напрямую измеряет вклад подхода — по доле отбраковки. Типовые ловимые ошибки: неподтвержденный механизм, неверный минеральный контекст, выдуманный реагент, несоответствие источнику.

План retrieval-ablation (значения заполняются после эталонной разметки):

Конфигурация	Recall@20	nDCG@10	MRR@10	Статус
Только dense	—	—	—	требуется разметка
Только FTS	—	—	—	требуется разметка
Гибрид	—	—	—	требуется разметка
Гибрид + реранкер	—	—	—	требуется разметка
Фасеты + гибрид + реранкер	—	—	—	целевая конфигурация

8. Доменная валидация

Проверка на «фабричную логику»: на типовых профилях потерь система должна выдавать направления, которые узнает любой обогатитель.

Профиль потерь	Ожидаемое направление	Фабричные «рычаги»
Ni/Cu в хвостах в закрытых сростках Pnt/Cp	Доизмельчение / переклассификация для раскрытия сростков [7]	шаровая загрузка, крупность помола, замкнутый цикл с классификацией
Потери в тонких и шламистых классах	Изменение гидроциклонной классификации / режима флотации [11]	песковая насадка, крупность слива, аэрация, время флотации
Селективность пирротин/пентландит/пирит	Реагентный режим [10]	pH/известь, ксантогенаты, депрессоры пирротина

Доменную достоверность обеспечивает корпус базовой литературы по обогащению, флотации и классификации [7][8][9][10] и по минералогии медно-никелевых руд [12]: он позволяет отличать

технологически правдоподобные направления от формально похожих, но слабых.

В демонстрационном прогоне на профиле хвостов КГМК (Ni 0.178%, 77.9% потерь в сростках Pnt/Cr во фракции +71 мкм) система выдала доменно ожидаемое направление — доизмельчение для раскрытия сростков никеля, с механизмом, рисками (энергопотребление, износ) и ссылкой на источник (Авдохин В.М., «Основы обогащения полезных ископаемых») [7]. Оценку эффекта в карточке гипотезы (в этом прогоне — снижение потерь на 5–10%) следует рассматривать не как прогноз внедрения, а как предварительный диапазон для приоритизации лабораторной проверки; финальная величина требует верификации на данных фабрики или bench-тесте. Отчет при этом честно пометил пробел в знаниях по данной точке потерь.

9. Бизнес-эффект

Мы не обещаем «сэкономим X миллиардов». Вместо этого — рамка приоритизации проверок:

$$V = \Delta_{\text{извлечение}} \times (\text{содержание металла в хвостах} \times \text{тоннаж}) \times \text{цена металла} \times P(\text{успех}) - (\text{CAPEX} + \text{OPEX} + \text{стоимость теста})$$

Все множители, кроме вероятности успеха (ее дает ансамбль критиков) и стоимости теста (ее дает roadmap проверки), — входные данные фабрики. Формула позволяет ранжировать гипотезы по деньгам без фейковых обещаний.

Внешний контекст: хвосты — известный источник критических металлов, включая никель; отвалы Норильского кластера имеют потенциал по цветным и благородным металлам с учетом минералогической специфики Cu-Ni-PGE сырья [12]. Конкретные величины должны прийти из данных площадки, а не из модели.

Формат для лица, принимающего решения, — карточка гипотезы: сила доказательной базы, оценка обоснования, новизна, реализуемость, ожидаемый KPI-эффект, стоимость теста, совместимость с оборудованием, риск. Поддерживается экспорт в 5 форматов, включая `report.jira.json` — гипотезы как задачи на верификацию в Jira Cloud.

10. Ограничения

- Извлечение схем и регламентов выполнено вручную. Для продакшена нужен автоматический vision-LLM в pyworker; шум OCR остается источником ошибок.
- Подход grounding-first по дизайну не дает предписаний «X→Y» там, где нет литературы об эффекте изменения. Это осознанный компромисс.
- Мультисэмплинг и self-consistency для генерации не реализованы. Основной выигрыш дал ансамбль критиков.

Источники


[1] Swanson, D. R. Fish oil, Raynaud's syndrome, and undiscovered public knowledge. Perspectives in Biology and Medicine, 30(1), 7–18, 1986. DOI: 10.1353/pbm.1986.0087.

[2] Gottweis, J., Weng, W.-H., Daryin, A., et al. Towards an AI co-scientist. arXiv:2502.18864, 2025. DOI: 10.48550/arXiv.2502.18864.

- [3] Ghafarollahi, A., & Buehler, M. J. SciAgents: Automating scientific discovery through multi-agent intelligent graph reasoning. arXiv:2409.05556, 2024. DOI: 10.48550/arXiv.2409.05556. Рецензируемая версия: Advanced Materials, DOI: 10.1002/adma.202413523.
- [4] Mandikal, P., & Mooney, R. Sparse Meets Dense: A Hybrid Approach to Enhance Scientific Document Retrieval. arXiv:2401.04055, 2024. DOI: 10.48550/arXiv.2401.04055.
- [5] Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. RAGAs: Automated Evaluation of Retrieval Augmented Generation. Proceedings of EACL 2024: System Demonstrations, 150–158, 2024. DOI: 10.18653/v1/2024.eacl-demo.16.
- [6] Gao, T., Yen, H., Yu, J., & Chen, D. Enabling Large Language Models to Generate Text with Citations. Proceedings of EMNLP 2023, 6465–6488, 2023. DOI: 10.18653/v1/2023.emnlp-main.398.
- [7] Авдохин В. М. Основы обогащения полезных ископаемых. Том 1. Обогачительные процессы. Москва: Горная книга (МГГУ). Учебник для вузов.
- [8] Авдохин В. М. Основы обогащения полезных ископаемых. Том 2. Технология обогащения полезных ископаемых. Москва: Горная книга (МГГУ). Учебник для вузов.
- [9] Абрамов А. А. Переработка, обогащение и комплексное использование твёрдых полезных ископаемых. Том 2. Москва: МГГУ. ISBN 5-7418-0242-7.
- [10] Глембоцкий В. А., Классен В. И. Флотационные методы обогащения. 2-е изд., перераб. и доп. Москва: Недра, 1981. 304 с.
- [11] Поваров А. И. Гидроциклоны на обогачительных фабриках. Москва: Недра, 1978. 232 с.
- [12] Генкин А. Д., Дистлер В. В., Гладышев Г. Д. и др. Сульфидные медно-никелевые руды норильских месторождений. Москва: Наука, 1981. 234 с.


Приложение 1. Поток обработки системы

Ряд 1 · поиск и извлечение фактов



↓ подтверждённые факты (claim_id) передаются в генерацию ↓

Ряд 2 · генерация, оценка, отчёт



Как читать. Один запрос `POST /v1/runs` проходит пять стадий (ряд 1: ①→③, ряд 2: ④→⑤) и возвращает ранжированный список проверяемых гипотез; ответ асинхронный — клиент получает `id` за 1–2 секунды и опрашивает статус. Два акцента: красный ромб — **grounding gate**, где цитату проверяет код, а не модель (непрошедший факт в базу не пишется и не может обосновать гипотезу), и зелёный узел — **воспроизводимое ранжирование** (взвешенная сумма кодом, а не ещё один вызов LLM). Пунктиром: оборудование фабрики подмешивается детерминированным SQL, а экспертный фидбэк обновляет граф репутации сущностей и влияет на будущие прогнозы.

Приложение 2. Доменная таксономия корпуса знаний

Иерархия предметных областей, покрываемых корпусом «Фабрики гипотез». Используется для трёх задач: курирование источников, доменная маршрутизация (domain + retrievalFacetsByDomain) и оценка полноты охвата.

Уровень	Что это	Число
L1	Крупные домены	~20
L2	Области внутри доменов	~100
L3	Подобласти / темы	~600
L4	Поисковые микротемы	1500+

Нижеследующая — развёртка L1 → L2 → L3. L4 (микротемы) строятся из L3 динамически при курировании и поиске.

L1-01 · Геология и минерально-сырьевая база

- L2 · Геология рудных месторождений** — Геология рудных месторождений; Геология золотых месторождений; Геология серебряных месторождений; Геология Cu-Ni-PGE месторождений; Геология Норильского рудного района; Рудная петрология; Геохимия руд; Генезис рудных месторождений; Строение рудных тел; Текстуры и структуры руд; Типизация руд.
- L2 · Классификация и оценка сырья** — Классификация полезных ископаемых; Классификация золотосодержащих руд; Классификация упорных руд; Геометаллургия; Технологическая оценка сырья; Экспрессная технологическая оценка руд; Пробоотбор и подготовка технологических проб.
- L2 · Минерально-сырьевая база** — Минерально-сырьевая база; Техногенные месторождения.

L1-02 · Экономика недропользования и ГРП

- L2 · Экономика ГРП** — Экономика недропользования; Экономика геологоразведочных работ; Организация геологоразведочного производства; Себестоимость геологоразведочных работ.
- L2 · Ресурсы геологоразведочного предприятия** — Ресурсы ГРП; Основные фонды; Оборотные средства; Трудовые ресурсы; Финансовые ресурсы.

L1-03 · Минералогия и технологическая минералогия

- L2 · Технологическая минералогия** — Минералогия; Технологическая минералогия; Process mineralogy.
- L2 · Минералогия руд по типам** — Минералогия золотых руд; серебряных; сульфидных; углистых; мышьяковистых; медистых; сурьмянистых; теллуридных; полиметаллических; Cu-Ni-PGE руд; Минералы платиновой группы.
- L2 · Минералогия отдельных минералов** — Пирит; арсенопирит; пирротин; халькопирит; сфалерит; галенит; молибденит; скородит.

L1-04 · Формы нахождения и раскрытие благородных металлов (deportment)

L2 · Формы нахождения золота и серебра — Формы нахождения золота; Формы нахождения серебра; Свободное золото; Тонкодисперсное золото; Субмикроскопическое золото; Невидимое золото.

L2 · Золото в минеральных матрицах — Золото в пирите; в арсенопирите; в углеродистом веществе; в теллуридах; в кварце; в оксидах железа.

L2 · Диагностика форм и раскрытия — Фазовый анализ золота; Диагностическое выщелачивание; Анализ раскрытия минералов; Анализ сростков минералов; Морфология минеральных зёрен; Поверхность минеральных зёрен.

L1-05 · Обогащение: общая теория и технология

L2 · Теория и процессы обогащения — Общая технология обогащения; Теория разделения минералов; Обогащительные процессы; Подготовительные / основные / вспомогательные / заключительные операции.

L2 · Показатели и схемы — Технологические показатели обогащения; Расчёты технологических показателей; Схемы обогащения; Режимы обогащения; Качество концентратов; Качество хвостов; Баланс металлов; Комплексное использование минерального сырья.

L2 · Переработка по видам сырья — Руды цветных / чёрных / редких / редкоземельных / благородных металлов; Угли; графит; алмазы; барит; тальк; слюда; асбест; апатиты; фосфориты; калийные руды; сера; железные; марганцевые; хромовые; золотосодержащие; полиметаллические; медные; медно-молибденовые; медно-никелевые руды.

L1-06 · Рудоподготовка (дробление и измельчение)

L2 · Теория рудоподготовки — Теория дробления; Теория измельчения; Теория грохочения; Крупность материала; Гранулометрический состав; Поверхность зёрен; Раскрытие минералов.

L2 · Схемы и стадии — Схемы рудоподготовки; Стадии дробления; Стадии измельчения; Замкнутые циклы измельчения.

L2 · Дробилки — Щековые; конусные; валковые; молотковые.

L2 · Мельницы — Шаровые; стержневые; Самоизмельчение; Полусамоизмельчение; SAG-мельницы; HPGR.

L2 · Расчёт и эксплуатация — Расчёт дробильного оборудования; Расчёт мельничного оборудования; Выбор оборудования рудоподготовки; Эксплуатация дробилок; Эксплуатация мельниц; Технологические характеристики дробилок и мельниц.

L1-07 · Классификация и грохочение

L2 · Грохочение — Грохочение; Ситовой анализ; Грохоты; Вибрационные грохоты; Дуговые сита.

L2 · Гидравлическая и гидроциклонная классификация — Гидравлическая классификация; Гидроциклонная классификация; Гидроциклоны; Теория / практика работы гидроциклонов; Тонкозернистая классификация; Граничное зерно классификации.

L2 · Параметры и управление — Расчёт гидроциклонов; Конструктивные / технологические параметры гидроциклонов; Пески гидроциклона; Слив гидроциклона; Циркулирующая нагрузка; Оптимизация классификации; Управление классификацией.

L1-08 · Гравитационное обогащение

L2 · Методы и аппараты — Промывка руд; Отсадка; Концентрационные столы; Винтовые сепараторы; Тяжёлосредное обогащение; Обогащение в тяжёлых суспензиях; Центробежное обогащение; Центробежные концентраторы; Knelson-концентраторы; Falcon-концентраторы.

L2 · Гравитация золота — Гравитационное извлечение золота; Гравитационно-флотационные схемы; Гравитационно-цианидные схемы.

L1-09 · Магнитное и электрическое обогащение

L2 · Магнитное обогащение — Магнитные методы; Физические основы; Магнитные свойства минералов; Магнитная восприимчивость; Классификация магнитных методов; Магнитные сепараторы; Слабо- / сильномагнитная сепарация; Высокоградиентная (ВГМС); Сухая / мокрая магнитная сепарация; Практика; Расчёт схем.

L2 · Электрическое обогащение — Электрические методы; Электростатическая сепарация; Коронная; Диэлектрическая; Электрические свойства минералов; Электрические сепараторы; Практика; Расчёт схем.

L1-10 · Радиометрическая сепарация и предконцентрация

L2 · Сенсорная сортировка — Рентгенорадиометрическая сепарация; Оптическая сортировка; Sensor-based sorting; XRT-сортировка; XRF-сортировка; LIBS-сортировка.

L2 · Предконцентрация — Предконцентрация руд; Удаление пустой породы до измельчения.

L1-11 · Флотация: теория и практика

L2 · Физико-химия флотации — Теория флотации; Физико-химические основы; Поверхностная химия минералов; Коллоидная химия; Межфазные взаимодействия; Минерал–вода–воздух; Смачиваемость; Гидрофобность; Краевой угол; Дзета-потенциал; Электрокинетика минералов; Адсорбция реагентов; Электрохимия сульфидных минералов; Поверхностные комплексы реагентов.

L2 · Кинетика и гидродинамика — Кинетика флотации; Селективность; Гидродинамика флотации; Пенообразование; Устойчивость пены; Промывка пенного слоя; Entrainment; Механический вынос частиц.

L2 · Схемы и режимы — Коллективная / селективная флотация; Прямая / обратная; Основная / контрольная / перечистная; Схемы флотации; Режимы флотации; Оборот чернового концентрата.

L2 · Флотация по типам сырья и крупности — Сульфидные / окисленные руды; Золотосодержащие; Упорные золотые; Углистые золотые; Тонкие / ультратонкие частицы; Шламы; Крупнозернистые частицы.

L2 · Аппаратурные методы флотации — Колонная флотация; Пневматическая; Jameson Cell; Flash flotation; Microbubble; Nanobubble flotation.

L1-12 · Флотационные реагенты

L2 · Классы реагентов — Собиратели; Пенообразователи; Депрессоры; Активаторы; Регуляторы pH; Модификаторы среды; Флокулянты; Коагулянты.

L2 · Собиратели по химии — Ксантогенаты; Дитиофосфаты; Аэрофлоты; Дитиазины; Сульфгидрильные собиратели; Амины; Карбоновые / жирные кислоты; Смешанные собиратели; Композиции собирателей.

L2 · Реагентные режимы — Реагентные режимы флотации; Депрессия пирита; Депрессия углеродистого вещества; Депрессия глин.

L1-13 · Флотационное оборудование

L2 · Конструкции флотомашин — Флотационные аппараты; Конструкции; Отечественные / зарубежные флотомашин; Технические характеристики; Камеры и их размеры; Аэрационные узлы; Импеллеры; Пневмомеханические / механические / пневматические / колонные флотомашин.

L2 · Инжиниринг флотомашин — Гидродинамика аппаратов; Моделирование устройств; Эффективность работы; Выбор флотомашин; Масштабирование; Развитие флотационной техники.

L1-14 · Обезвоживание и водно-шламовое хозяйство

L2 · Процессы обезвоживания — Дренажное; Сгущение; Фильтрование; Центрифугирование; Сушка концентратов / угольных продуктов; Отделение жидкой фазы от твёрдой; Влажность концентратов и хвостов.

L2 · Аппараты — Сгустители; Фильтры; Центрифуги; Сушильные аппараты; Пылеулавливание; Обеспыливание.

L2 · Водно-шламовое хозяйство — Обратная вода; Очистка обратной воды; Замкнутый водооборот.

L1-15 · Хвостовое хозяйство и переработка хвостов

L2 · Хвосты — Хвосты обогащения; Хвосты флотации; Хвосты цианирования; Переработка хвостов.

L2 · Складирование и обезвреживание — Складирование хвостов; Хвостохранилища; Управление хвостохранилищами; Обезвреживание хвостов; Рекультивация хвостохранилищ; Очистка сточных вод.

L1-16 · Металлургия благородных металлов: цианирование и сорбция

L2 · Основы металлургии БМ — Теоретические основы; Металлургия золота / серебра / платиновых металлов; Физико-химия золота и серебра; Химия комплексных соединений золота и серебра; Гидро- / пирометаллургия; Комбинированные схемы извлечения.

L2 · Производство и аффинаж — Производство золота / серебра / платиновых металлов; Получение сплава доре; Плавка золотосодержащих осадков; Аффинаж золота / серебра / платиновых металлов.

L2 · Цианирование — Цианирование золота / серебра; Кинетика / термодинамика цианирования; Растворение золота и серебра в цианистых растворах; Роль кислорода / pH / Eh; Цианисиды; Расход

цианида; Агитационное / кучное / сорбционное цианирование; Цианирование после флотации / обжига / POX / BIOX / Albion.

L2 · Сорбция и выделение — Сорбция золота / серебра; Активированный уголь; Сорбция золото-цианидного комплекса; CIP; CIL; CIC; RIP; RIL; Ионообменные смолы; Десорбция / элюирование золота; Регенерация угля; Электровыделение / электролиз золота; Цементация цинком; Merrill–Crowe.

L1-17 · Упорные руды и предварительное окисление

L2 · Типы упорности — Упорные золотосодержащие руды и концентраты; Золото-серебряные; Пиритные; Мышьяково-пиритные; Арсенопиритные; Феррозолотые; Скородитовые; Марганцовистые; Полиметаллические; Медистые; Сурьмянистые; Пирротинсодержащие; Теллуристые; Глинистые; Углистые золотые руды; Двойная упорность; Preg-robbing.

L2 · Диагностика упорности — Факторы технологической упорности; Классификация упорных руд; Экспрессная оценка упорности; Вскрытие сульфидной / углеродистой матрицы; Подготовка к выщелачиванию; Выбор схемы переработки упорного сырья.

L2 · Окислительная предобработка — Окислительный обжиг; Обжиг сульфидных / мышьяковистых концентратов; Автоклавное окисление; Pressure oxidation (POX); Низкотемпературный / щелочной POX; Атмосферное окисление; Биоокисление; BIOX; Albion Process; Ультратонкое измельчение; IsaMill; Термическая / термо-паровая / микроволновая предобработка; Сравнение roasting / POX / BIOX / Albion.

L1-18 · Альтернативное (бесцианидное) выщелачивание

L2 · Бесцианидные лиганды — Тиокарбамидное / тиомочевинное; Тиосульфатное; Аммиачно-тиосульфатное; Глициновое; Тиоцианатное; Хлоридное; Галоидное; Йодидное; Бромное; Гипохлоритное; Политионатное выщелачивание.

L2 · Сравнение схем — Бесцианидное выщелачивание золота; Сравнение цианидных и бесцианидных схем.

L1-19 · Проектирование, оборудование и автоматизация фабрик

L2 · Проектирование фабрик — Проектирование обогатительных / золотоизвлекательных фабрик; Проектно-сметная документация; Технологический расчёт схем; Выбор схем и оборудования; Расчёт оборудования; Генеральный план; Компоновка; Размещение оборудования; Укрупнённые ТЭП; Производительность; Материальные / водные / реагентные потоки; Энергопотребление; Эксплуатация фабрик; Ремонт и обслуживание; Промышленная безопасность.

L2 · Оборудование фабрик — Дробильное; измельчительное; классификационное; грохоты; гидроциклоны; флотомшины; магнитные / электрические сепараторы; гравитационные аппараты; сгустители; фильтры; центрифуги; сушилки; автоклавы; реакторы выщелачивания / биоокисления; сорбционные колонны; электролизёры; печи обжига; плавильные печи; системы дозирования реагентов; насосы и пульпопроводы; газоочистное / пылеулавливающее оборудование.

L2 · Контроль и автоматизация — Автоматизация обогатительных / золотоизвлекательных фабрик; Контроль технологических процессов; Онлайн-анализаторы; Контроль крупности / плотности пульпы / pH / Eh / расхода реагентов / качества концентрата и хвостов; Моделирование процессов;

Оптимизация процессов; Машинное обучение в обогащении; Машинное зрение; Цифровые двойники фабрик; Process control; APC-системы.

L1-20 · Аналитика, экология, вторичное сырьё и промышленные кейсы

L2 · Аналитика и лабораторные методы — Пробирный анализ; Химический анализ руд; Анализ золота / серебра / платиновых металлов / серы / мышьяка / углерода / цианидов / тиосульфата; Гранулометрический / ситовой анализ; Лазерная дифракция; XRD; XRF; SEM-EDS; ICP-OES; ICP-MS; Дзета-потенциал; Краевой угол; Флотационные тесты; Bottle-roll tests; Column leach tests; Preg-robbing tests; Сорбционные тесты; Кинетические тесты выщелачивания; Пилотные / полупромышленные испытания.

L2 · Экология переработки — Экология золотодобычи; Экологическая безопасность обогащения и гидрометаллургии; Обезвреживание цианидов / стоков / хвостов; INCO SO₂/Air; Пероксидное разрушение цианидов; Био- / фиторемедиация; Мышьяк в золотодобыче; Стабилизация мышьяка; Скородит; Газоочистка при обжиге; Замкнутый водооборот; Рекультивация хвостохранилищ; ESG в горно-металлургической отрасли.

L2 · Вторичное сырьё БМ — Электронный лом; Печатные платы; Анодные / медноэлектролитные шламы; Катализаторы; Ювелирный лом; Техногенное золотосодержащее сырьё; Гидро- / биогидрометаллургия e-waste; Сорбционное извлечение и электровыделение золота из e-waste; Циркулярная экономика БМ.

L2 · Промышленные кейсы и ТЭО — Кейсы флотации золотых руд; переработки упорных руд; POX; BIOX; Albion; CIL/CIP; Merrill-Crowe; тиосульфатного выщелачивания; переработки хвостов и техногенного сырья; Сравнение технологических маршрутов; CAPEX/OPEX переработки руд; Технико-экономическая оценка фабрик; Выбор оптимальной технологии; Промышленное внедрение; Масштабирование лабораторных технологий до промышленности.

Как таксономия используется в системе

- **Курирование корпуса** — целевой поиск источников по темам; автоматический разведчик corpus-scout (каталог Geokniga) доводит охват до целевых ~600 тем L3.
- **Доменная маршрутизация** — поле domain y documents / chunks (по умолчанию flotation) + фасеты retrievalFacetsByDomain . Подключение нового домена = ingestion с другим domain , без изменения ядра пайплайна.
- **Широта доказательной базы** — одна гипотеза может опираться на факты из нескольких доменов одновременно (минералогия сростков + теория раскрытия + практика классификации).